

—— 未 来 技 术 学 院 ——

Deep Learning for Inertial Position: A Survey

综述汇报

姓 名 : 芮 文 惠

日期: 2024年10月 18日

目录 / CONTENTS

01

选题背景意义

03

基于学习的人体运动
分析和活动识别

02

深度学习在惯性定位
的应用

04

评估和面临的挑战

01

选题背景意义

🎯 惯性定位是什么？

惯性定位（Inertial Navigation System, INS）是一种利用惯性传感器（如加速度计和陀螺仪）测量无人机、船或车辆在空间中的加速度和角速度，并通过积分得到位置、速度和方向的系统。



误差源


1. 确定性误差：偏置误差，非正交性误差，不对准误差，比例因子误差，温度相关误差，积分累计误差，误差漂移。
2. 随机误差：随机传感器噪声，长期运行产生的随机行走噪声。



IMU运动学模型

$$\begin{aligned}\mathbf{R}_b^n(t+1) &= \mathbf{R}_b^n(t) \mathbf{R}_{b_{t+1}}^{b_t} \\ \mathbf{v}_n(t+1) &= \mathbf{v}_n(t) + \mathbf{a}_n(t)dt \\ \mathbf{p}_n(t+1) &= \mathbf{p}_n(t) + \mathbf{v}_n(t)dt + \frac{1}{2}\mathbf{a}_n(t)dt^2\end{aligned}$$

1. 更新方向。
2. 对加速度积分更新速度。
3. 对速度积分更新位置。



1. 积分得到速度

$$\begin{cases} V_E = V_{E_0} + \int_0^t a_E dt \\ V_N = V_{N_0} + \int_0^t a_N dt \\ V_U = V_{U_0} + \int_0^t a_U dt \end{cases}$$


2. 再积分得到位移

$$\begin{cases} \lambda = \lambda_0 + \int_0^t \frac{V_E}{(R+h)\cos\varphi} dt \\ \varphi = \varphi_0 + \int_0^t \frac{V_N}{R+h} dt \\ h = h_0 + \int_0^t V_U dt \end{cases}$$



存在的问题

由于测量误差不可避免，并且会在短时间内给没有约束的惯性系统产生误差漂移。



🎯 以前如何解决？

1. 通过结合特定领域知识。

2. 结合其他传感器。



通过IMU与其他传感器集成，如相机，激光雷达，磁力计等可以提供需要的数据，通过融合多个传感器的数据，使估计姿态的准确性提升

1

行人航位推算 (PDR)

利用已知起始位置，结合随着时间的推移而估算的移动速度和前进方向，来推定未来到达位置的过程

包括三个主要步骤：

①步长检测。②航向估计。③位置更新。

优点：PDR有效地减少而了惯性定位漂移。

局限性：出现不准确的步长检测和步长估计误差时它无法自行纠错。

2

零速度更新 (ZUPT)

在行人航位推算领域，通过结合卡尔曼滤波器，将加速度计和陀螺仪数据融合，估计姿态。通过识别人类行走的静止相位，并将零速度用于卡尔曼滤波器中的，用做观测值，补偿SINS的误差。

优点：有效限制开环积分的有效漂移。

局限性：任何不正确的静止相位检测或小的干扰可能会导致导航系统漂移，并且只限于行人跟踪，应用范围小。

为什么需要引入深度学习？

- 1、深度学习具有强大的非线性建模能力，能够捕捉惯性数据中的复杂模式和关系。
- 2、深度学习可以自动从原始惯性数据中提取有效的特征。
- 3、深度学习能够有效融合来自不同传感器的数据（如IMU、GPS、视觉传感器等），从而综合多种信息提高定位精度。
- 4、深度学习模型可以在存在噪声和不确定性的情况下仍然提供可靠的估计。
- 5、支持动态环境中的即时定位与导航。
- 6、可以用于实时自适应策略，适应复杂情况。



传感器层面 → 学习标定惯性传感器



算法层面 → 学习纠正IMU集成

→ 基于学习的IMU的融合定位



应用层面 → 学习纠正行人惯性定位

→ 学习车辆、无人机和机器人惯性定位校正

→ 学习传感器融合在IMU集成定位中的应用

→ 基于学习的人体运动分析与活动识别

02

深度学习在惯性定位的应用

从三个层面分别介绍基于深度学习的惯性定位方法

如何学习标定惯性传感器

以前标定惯性传感器时通常依赖于线性或简单的模型描述误差，无法处理更复杂的数据模式，并且一般在数据采集后进行标定，实时性差，在应用于复杂环境时表现不佳。

标定是什么意思？

校正传感器测量数据中的系统误差。



标定方法有哪些？

1. 静态标定
2. 动态标定
3. 基于模型的标定



为什么要标定？

通过标定，使确定性误差被识别并且加以校正，从而改善传感器的精度

深度学习时代之前有人曾提出一层神经网络 (ANN) 模拟陀螺仪漂移分布，与基于KF标定的优势：无需提前设置超参数（例如传感器噪声矩阵）
Computer, vol. 29, no. 3, pp. 31-44, Mar. 1996.



标定有哪些好处？

1. 提高精度
2. 支持多传感器融合
3. 增强可靠性

标定步骤

确定误差类型→数据采集→计算误差→校准模型构建→应用校准参数→验证

🎯 如何基于深度学习标定惯性传感器？

in Proc. IEEE Nat. Aerosp. Electron. Conf. (NAECON), Jul. 2018, pp. 197–202.

使用卷积神经网络 (ConvNet) 去除惯性测量误差噪声。步骤：低精度IMU数据作为输入，高精度IMU参考数据作为标签训练网络，尝试输出加速度和角速率参考。

01

局限性：未在真实导航设置进行应用。

orinet -IEEE Robot.

Autom. Lett., vol. 5, no. 2, pp. 399–406, Apr. 2020

calib-net---IEEE Trans. Instrum. Meas., vol. 71, pp. 1–9, 2022

通过产生基于神经网络产生更精准的惯性数据，然后集成到方向估计中。

OriNet将陀螺仪信号输入到LSTM中校准信号，评估显示定向性能提高80%。类似方法还有ConvNet。此外，Calib-Net基于膨胀ConvNet从惯性数据中提取时空特征对陀螺仪数据降噪。

02

还可以将学习到的初始标定模型结合到视觉惯性测距系统中，进一步提升了定位精度。

局限性：学习到的误差模型取决于特定传感器或平台，并且需要分析哪些噪声可以被有效去除。

通过生成改进经典校准算法的参数。

例子：将惯性传感器建模成马尔可夫决策过程，提出深度强化学习生成最佳校准参数，并证明了在VIO系统的有效性。

03

Int. J. Robot. Res., vol. 38, nos. 12–13, pp. 1388–1402, Oct. 2019.
R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction. Cambridge, MA, USA: MIT Press, 2018



如何学习纠正IMU集成？

- 1.什么是纠正IMU集成？  IMU集成即对IMU数据的积分
- 2.为什么要引入深度学习纠正集成？

特性	传统纠正IMU集成	深度学习纠正IMU集成
建模方式	基于物理模型和数学假设	数据驱动，自动学习非线性误差模型
误差处理能力	线性化误差处理较好。非线性误差难以处理	擅长处理复杂的非线性误差和动态误差模式
依赖的先验知识	需要详细的物理模型和噪声模型	依赖大量数据，模型自动学习
适应性	需要人为调整参数。应对不同环境需要重新调整	具备自适应性，能应对环境和传感器变化
多传感器融合	需要手动设计融合策略	能自动学习融合不同的传感器数据，处理多模态信息
数据需求	少量数据即可	需要大量数据
泛化能力	基于物理模型，理论上泛化能力较强	可能在训练数据外的场景泛化能力较弱



基于深度学习有哪些方法可以纠正IMU集成？

基于深度学习习惯性定位中，用户的绝对速度可以用深度学习从IMU序列中推断出来，速度信息可以作为关键约束来减少IMU双积分中的漂移。

01 学习位移位置

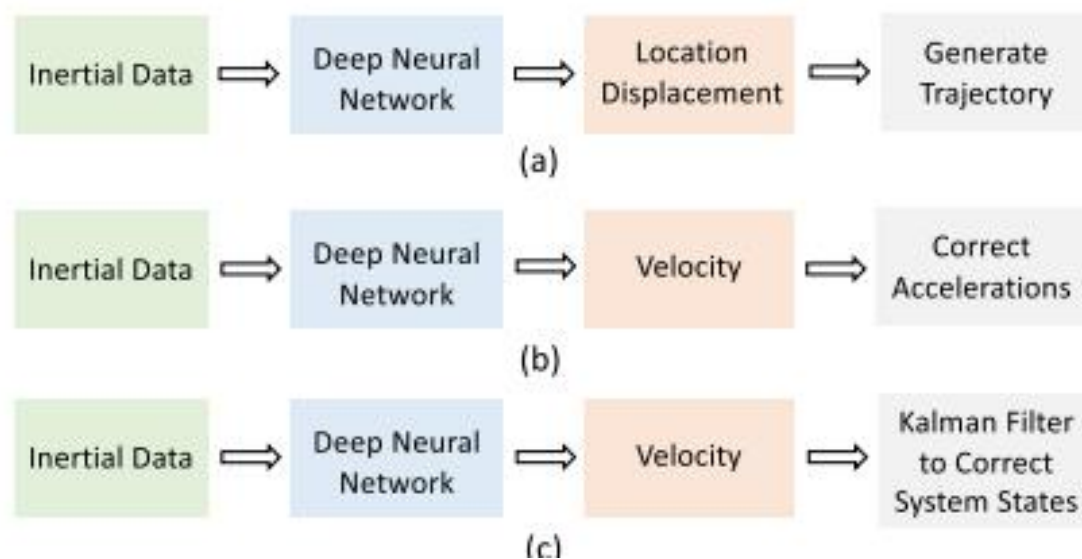
第一种方法将惯性定位表述为顺序学习问题，二维运动位移从分割的惯性数据独立窗口学习，跟踪人或轮式设备可以通过IMU测绝对移动速度，于是提出IONet,基于LSTM的相对姿态端到端学习，并且基于监督学习。结果：定位误差在90%情况下3米内。优势：小车跟踪时，显示出与代表性视觉惯性里程计相当性能，不足：需要高精度姿态作为训练标签，且泛化能力较弱。

为了提升泛化能力，有人提出MotionTransformer,允许模型生成对抗网络和领域自适应。

还有人提出可以产生姿态不确定性以及姿态，提供学习姿态可以信任的程度。

为了实现全3D定位，TLIO提出从一系列重力对准的惯性数据中学习3D位置和协方差。并且为了避免初始方位的影响，惯性数据被转换成局部重力对准帧。

结果：在 3-7 分钟 的人 体 运 动 中，TLIO定位误差90%情况在3米以内。



RIDI-H. Yan, Q. Shan, and Y. Furukawa, "RIDI: Robust IMU double integration," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2018, pp. 621–636

ronin--S. Herath, H. Yan, and Y. Furukawa, "RoNIN: Robust neural inertial

navigation in the wild: Benchmark, evaluations, new methods," in Proc.

IEEE Int. Conf. Robot. Autom. (ICRA), May 2020, pp. 3146–3152

RIDI→ 训练神经网络预测速度矢量，减去重力矫正加速度。利用人的步行速度做先验补偿漂移。

定位环境：室内



局限性：训练数据依赖、步行速度变化、重力矫正准确性、计算复杂性以及环境适应性等多种局限性



RoNIN→**NILoc**(实验)：解决了神经惯性定位问题。从惯性运动历史推断全局位置。认识到人类运动模式在不同位置独一无二。

基于**transformer**的**DNN**框架将速度序列转换为位置。



S. Herath, D. Caruso, C. Liu, Y. Chen, and Y. Furukawa, "Neural inertial localization," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Jun. 2022, pp. 6594–6603.

RIDI→**RoNIN**：惯性测量和速度矢量转换为与航向无关的坐标系，引入新的速度损失。**z**轴设置于重力对齐。

定位环境：室外



优点：**RoNIN** 可以有效地减少因设备航向变化所引入的误差。

局限性：依赖于方向估计



局限性：开放空间，对称或者重复的地方，可能不存在独特的运动模式。



S. Sun, D. Melamed, and K. Kitani, "IDOL: Inertial deep orientation estimation and localization," in Proc. AAAI Conf. Artif. Intell., vol. 35, 2021, pp. 6128–6137

RIDI, RoNIN, TLIO依赖于设备方向将惯性数据旋转到合适的帧，基于此，IDOL提出先从数据中学习方向，然后将惯性数据旋转到合适的帧，再学习位置。还可以用磁性数据估计方向再与学习的里程计相结合，减少对设备方向的依赖还可以减少定位漂移。

03

学习速度纳入KF更新过程

S. Cortés, A. Solin, and J. Kannala, "Deep learning based speed estimation for constraining strapdown inertial navigation on smartphones," in Proc. IEEE 28th Int. Workshop Mach. Learn. Signal Process. (MLSP), Sep. 2018, pp. 1–6.

速度放入KF更新

使用`ConvNet`从IMU序列推断当前速度，将该速度纳入`kf`滤波器，约束漂移。该方法使用全速作为观测值。
优点：结合学习速度可以处理更复杂的人体运动。



类似实验

基于`DNN`，推断身体行走速度，与扩展`KF`相结合，除了学习到速度还可以产生一个噪声参数动态更新参数。

Y. Wang, H. Cheng, and M. Q.-H. Meng, "Pedestrian motion tracking by using inertial sensors on the smartphone," in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst. (IROS), Oct. 2020, pp. 4426–4431.



什么是IMU集成定位？→ IMU集成定位的基本原理是通过传感器的数据进行处理，以估算物体的位置和方向。

对比

特性	传统IMU集成定位	基于深度学习的IMU集成定位
数据处理方式	基于数学模型和滤波算法	基于深度神经网络
准确性和适应性	准确性受限于传感器噪声和模型误差；适应性：对于已知模型场景表现较好	准确性通过学习复杂模式提高定位精度；适应性：能够适应多种动态环境和运动模式
特征提取	手动提取，依赖领域知识	自动提取，减少人工干预
实时性	实时性能较好，但在动态变化时可能滞后	依赖于模型复杂度，实时性不同
适用场景	静态或者低动态环境	高动态，复杂环境的定位需求

01

基于学习的视觉惯性定位

是一种结合视觉信息（如摄像头捕获的图像）和惯性测量单元（IMU）数据进行定位和导航的技术。通过使用深度学习模型，可以有效处理和融合这些多模态数据，以提高定位精度和鲁棒性。

02

基于学习的IMU/GNSS组合定位

结合惯性测量单元（IMU）和全球导航卫星系统（GNSS）数据的定位技术，

03

学习融合IMU与其他传感器



视觉惯性里程计：视觉惯性里程计（Visual-Inertial Odometry, VIO）通过结合摄像头的图像数据和IMU的加速度、角速度数据来估计设备的相对运动。单目视觉可以捕捉场景外观但无法恢复缩放指标。IMU提供公制尺度。

R. Clark, S. Wang, H. Wen, A. Markham, and N. Trigoni, "VINet: Visual-inertial odometry as a sequence-to-sequence learning problem," in Proc. Conf. Artif. Intell. (AAAI), 2017, pp. 3995–4001.

VINet是端到端模型，由一个基于ConvNet的视觉编码器和一个基于LSTM的惯性编码器组成。与传统的相比更强鲁棒性。

特性	传统VIO	基于学习的VIO
特征提取	依赖经典算法	卷积神经网络
数据处理	使用滤波器，固定滞后平滑或完全平滑	深度学习模型端到端状态估计
训练需求	无需	需要大量标注数据训练
系统集成	简单	可能需要重新设计系统架构



C. Chen et al., "Selective sensor fusion for neural visual-inertial odometry," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Jun. 2019, pp. 10534–10543.

为了有效整合视觉信息和惯性信息，提出了一种选择性传感器融合机制，该机制根据传感器观测结果学习重要特征。提出硬融合和软融合。与直接拼接信息相比，性能提升5%-10%。

vio learner—E. J. Shamwell, K. Lindgren, S. Leung, and W. D. Nothwang, "Unsupervised deep visual-inertial odometry with online error correction for RGB-D imagery," IEEE Trans. Pattern Anal. Mach. Intell., vol. 42, no. 10, pp. 2478–2493, Oct. 2020.

监督学习训练需要获得高精度IMU姿态，成本昂贵，因此提出基于自监督的VIOs，利用连续图像的多视图几何关系作为监督信号。VIO Learner和DeepVIO,姿态变换是由惯性数据生成，并用于新的视图合成。

deepvio—L. Han, Y. Lin, G. Du, and S. Lian, "DeepVIO: Self-supervised deep learning of monocular visual inertial odometry using 3D geometric constraints," in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst. (IROS), Nov. 2019, pp. 6906–6913.

unvio—P. Wei, G. Hua, W. Huang, F. Meng, and H. Liu, "Unsupervised monocular visual-inertial odometry network," in Proc. 29th Int. Joint Conf. Artif. Intell., Jul. 2020, pp. 2347–2354.
selfvio—Y. Almalioglu, M. Turan, M. R. U. Saputra, P. P. B. de Gusmão, A. Markham, and N. Trigoni, "SelfVIO: Self-supervised deep monocular visual-inertial odometry and depth estimation," Neural Netw., vol. 150, pp. 119–136, Jun. 2022.



Unvio和SelfVIO，惯性数据通过应用于从图像和IMU序列中提取的串联视觉和惯性特征的注意力模块与视觉数据集成。结果：可以提升姿态估计的精度，特别是旋转估计。

以前通常使用KF融合数据。

02 基于学习的IMU/GNSS组合定位 (1)

D.-J. Jwo, C.-H. Chuang, J.-Y. Yang, and Y.-H. Lu, "Neural network assisted ultra-tightly coupled GPS/INS integration for seamless navigation," in Proc. 12th Int. Conf. ITS Telecommun., Nov. 2012, pp. 385–390.

Z. Li, J. Wang, B. Li, J. Gao, and X. Tan, "GPS/INS/odometer integrated system using fuzzy neural network for land vehicle navigation applications," J. Navigat., vol. 67, no. 6, pp. 967–983, Nov. 2014.

INS信息转换为多普勒数据，并于GNSS跟踪环路集成，减轻多普勒效应对GNSS的影响。结合径向基函数神经网络和基于自适应网络的模糊推理系统，有效弥补了GNSS中断，提高了系统的鲁棒性。

02---S. Hosseinyalamdary, "Deep Kalman filter: Simultaneous multi-sensor integration and modelling; a GNSS/IMU case study," Sensors, vol. 18, no. 5, p. 1316, Apr. 2018.

03---C. Shen, Y. Zhang, J. Tang, H. Cao, and J. Liu, "Dual-optimization for a MEMS-INS/GPS system during GPS outages based on the cubature Kalman filter and neural networks," Mech. Syst. Signal Process., vol. 133, Nov. 2019, Art. no. 106222.

一种基于深度学习的KF方法，结合建模步骤以及扩展KF的预测和更新步骤，在GNSS测量帮助下解决IMU误差并且纠正漂移。

S. Lu, Y. Gong, H. Luo, F. Zhao, Z. Li, and J. Jiang, "Heterogeneous multi-task learning for multiple pseudo-measurement estimation to bridge GPS outages," IEEE Trans. Instrum. Meas., vol. 70, pp. 1–16, 2021.

C. Shen et al., "Seamless GPS/Inertial navigation system based on self-learning square-root cubature Kalman filter," IEEE Trans. Ind. Electron., vol. 68, no. 1, pp. 499–508, Jan. 2021.

此外，提出的方法是扩展了双重优化概念，引入两个神经网络优化GNSS中断的INS/GNSS导航。第一个补偿漂移，第二个矫正滤波过程误差，径向基函数获得位置。

缺乏GNSS信号时，有一种多任务学习方法，使用卷积自编码器对数据去噪，再使用时间卷积网络处理。第二种方法SL-SRCKF，引入LSTM，误差预测能力增强。

F. Wu, H. Luo, H. Jia, F. Zhao, Y. Xiao, and X. Gao, "Predicting the noise covariance with a multitask learning model for Kalman filterbased GNSS/INS integrated navigation," IEEE Trans. Instrum. Meas., vol. 70, pp. 1–13, 2021.

[100] Y. Xiao et al., "Residual attention network-based confidence estimation algorithm for non-holonomic constraint in GNSS/INS integrated navigation system," IEEE Trans. Veh. Technol., vol. 70, no. 11, pp. 11404–11418, Nov. 2021.

为了细化滤波参数，引入基于时间卷积网络的框架，要学习测量噪声协方差参数和过程噪声协方差参数，与经典综合定位相比，精度更高。此外，还可以通过带有注意机制的残差神经网络，预测噪声协方差矩阵的单个速度元素。这个方法证明了车辆动态运动期间调整非完整约束不确定性提高了定位精度。

03 学习IMU与其他传感器融合

M. R. U. Saputra et al., "DeepTIO: A deep thermal-inertial odometry with visual hallucination," IEEE Robot. Autom. Lett., vol. 5, no. 2, pp. 1672–1679, Apr. 2020.

C. X. Lu et al., "MilliEgo: Single-chip mmWave radar aided egomotion estimation via deep sensor fusion," in Proc. 18th Conf. Embedded Netw. Sensor Syst., Nov. 2020, pp. 109–122.

- DeepTIO和MilliEgo采用类似软融合的基于注意力的选择性融合机制，对关系和视觉数据特征进行重加权和融合，提升姿态精度

- 基于无监督学习的LIDAR-inertial odometry从IMU序列生成运动变换，用于LIDAR新试图合成。促进自运动的自监督。

Y. Tu and J. Xie, "UnDeepLIO: Unsupervised deep LiDAR-inertial odometry," in Proc. Asian Conf. Pattern Recognit. Cham, Switzerland: Springer, 2022, pp. 189–202.



讨论深度学习具体解决行人导航算法的特定方面---PDR和ZUPT

01 学习纠正行人航位推算

误差源来自不准确的步幅估计和航向估计。

首先讨论如何更准确估计步幅。

- 1.SmartStep,在各种运动模式步骤检测中出现99%准确率。与之前相比,它不需要IMU固定位置,特定运动模式或预校准和阈值设置。
- 2.设计使用LSTM从原始数据回归步幅。已在人体运动证明有效性。
- 3.StepNet学习动态估计步长,与静态相比,误差率2.1%-3.1%。

考虑IMU附着模式会影响步幅估计,因此Bo等人采用领域自适应提取用于步幅估计的领域不变特征,增强了新领域的性能。

其次讨论如何更准确估计航向。

- 1.wang等人利用空间变换器网络和LSTM附接到无线设备惯性传感器学习方向。但存在问题即设备行进方向与行人行进方向未对准,使得难以估计方向。
- 2.为了解决这个问题,提出引入深度神经网络估计行走方向。这项工作报告了10°的航向误差。
- 3.PDRNet遵循传统PDR流程,使用深度神经网络取代补偿和航向估计模块,证明,学习步长和航向一起比分别学习好。

02 学习纠正ZUPT

由于检测基于阈值的零速度由于人类活动的复杂性变得困难,因此采用深度学习的分类功能,对是否处于ZUPT进行分类。

1.提出六层LSTM网络检测零速度。与基于固定阈值的零速度更新相比,定位误差降低了34%以上,并在各种混合运动展现出更强的鲁棒性。

2.利用卷积神经网络设计自适应ZUPT,基于IMU序列对ZVD进行更新。不用考虑不同用户、运动模式和附着模式。

学习在车辆、无人机和机器人平台上校正惯性定位



从惯性数据中学习误差协方差，并将其合并到 k 尔曼滤波中更新状态。已被证明可以提高惯性定位性能。*ODONET*，提出类似于行人的*ZUPT*，检测零速度相位。那之后，提出深度学习检测零速度相位。

PART 01 车辆方面

M. Brossard, A. Barrau, and S. Bonnabel, "AI-IMU dead-reckoning," IEEE Trans. Intell. Vehicles, vol. 5, no. 4, pp. 585–595, Dec. 2020.



在*LONet*基础上，提出*AbolDeeolO*，一种改进的三通道*LSTM*，可以根据惯性数据序列中预测无人机极向量。已进行评估，比传统视觉惯性里程计性能更好。另一个方法推导出仅与*IMU*数据序列相关的运动模型，提供了理论指导，在无人机数据集进行了训练。

PART 02 无人机

M. Abolfazli Esfahani, H. Wang, K. Wu, and S. Yuan, "AbolDeepIO: A novel deep inertial odometry network for autonomous vehicles," IEEE Trans. Intell. Transp. Syst., vol. 21, no. 5, pp. 1941–1950, May 2020



基于学习的惯性里程计扩展到有腿机器人将学习的位移与运动学模型结合，估计高频下的机器人系统运动。并且成功进行了实验，照明不良且特征跟踪失败的矿井中行走了20分钟。

PART 03 机器人

“

真实世界部署基于学习的惯性导航

基于真实世界部署，必须考虑预测精度和模型效率，在资源受限的设备上部署神经惯性里程计，TinyOdom提出基于时间卷积轻量模型学习位移，并通过NAS优化模型，将模型大小减小到31-134倍.在跟踪行人，动物空中和水下航行器进行了评估，60秒内定位误差在2.5-12米之间。

”

学习传感器融合在IMU组合定位中的应用→强调对传感器数据和误差模型的理解处理



IMU/GNSS紧密集成对于提供精确定位十分重要。现研究方法主要是利用深度学习模拟IMU/GNSS/中的误差漂移或者侧重于学习基本滤波参数以便于kf中进行有效融合。主要目的为了补偿定位漂移和估计参数。

PART 01 车辆方面



运行场景复杂，因此使深度学习干预通过神经网络提取更可靠的特征来解决视觉惯性系统变得脆弱的情况下实现精确的定位，其次基于自监督的视觉惯性定位的端到端训练最大限度利用了数据并且提供了深度估计。

PART 02 智能无人平台



之前的方法是使用视觉或激光雷达辅助定位通过图像和点云之间的特征关联校正漂移。集成系统需要更多计算，因此采用知识提取将教师网络压缩为轻量级版本。图像质量下降情况下，利用热传感器或者毫米波雷达集成IMU。Deeptio和Milliego利用基于生成模型的框架从热图像或毫米波雷达点云提取特征，提供姿态估计。

PART 03 室内行人导航

03

基于学习的人体运动 分析和活动识别

基于学习的人体运动分析和活动识别

① 人体运动分析

从惯性数据提取的手运动特征的人
类姿势识别参数学习




Figure 6.
Smoking gesture visualization using sensor data obtained from the two IMUs placed on the upper arm and the wrist.

左：我们利用现有的动作捕捉数据集，从放置在SMPL网格上的虚拟传感器合成IMU信号。中间：循环神经网络以IMU信号为输入，预测SMPL位姿参数。右图：该系统实时运行，只需6个传感器就能恢复全身姿势。
该文章提出了深度惯性姿势。基于RNN，从6个IMU重构身体姿势。

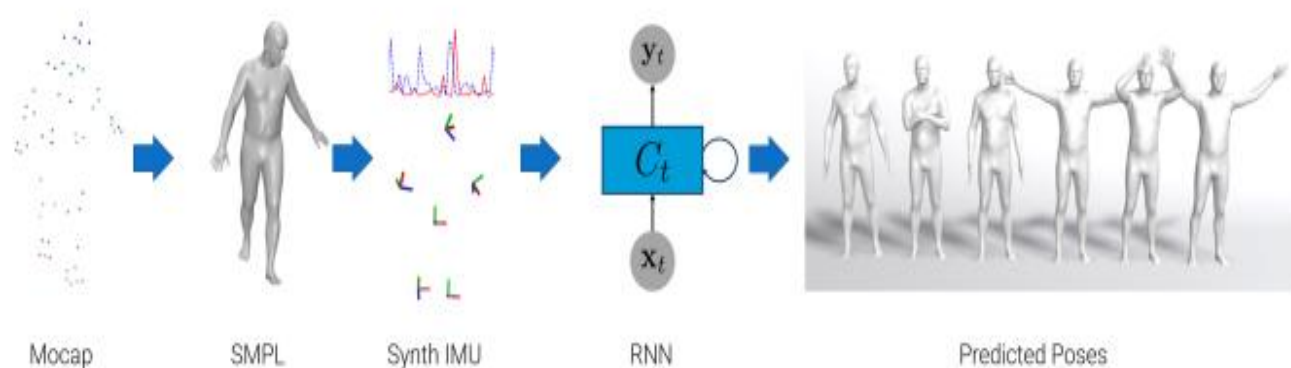



Fig. 2. Overview: *Left*: We leverage existing Mocap datasets to synthesize IMU signals from virtual sensors placed on a SMPL mesh. *Middle*: A recurrent neural network takes IMU signals as input and predicts SMPL pose parameters. *Right*: The system runs in real-time and can recover full body pose from just 6 sensors.

人体运动分析

使用监督支持向量回归估计人类行走的膝盖角度

从六个附着在身体上的IMU，基于RNN框架实现全身姿势重建和实时人体姿态估计



多层感知器等机器学习方法已被用于imu数据中学习用于人体运动重建的传感器位移

将神经运动学估计器与无物理感知运动优化器相结合。提高运动跟踪的准确性。

🎯 人类活动识别

流行的人类活动识别公共数据集，使用支持向量机将活动分类分为六类：行走，站立不动，坐着，走下楼，走上楼，躺下

深度学习还可以通过分析传感器惯性信息评估日常活动有效检测帕金森并且可以为运动员训练提供指导。



一种基于lstm的HAR模型，输入一系列惯性数据并输出类别概率。



基于convnet的HAR模型，准确率97%优于基于svm的96%准确率



提出一种学习框架，既利用DNN自动提取，也利用手工制作特征，在低端设备实现准确、实时的人类活动识别。

04

评估和面临的挑战

基于深度学习领域评估惯性定位有效性



绝对轨迹误差-ATE

整个轨迹实际位置和预测位置之间的平均均方根误差，较低ATE表示较好的性能。

VS



相对轨迹误差-RTE

指定时间间隔内实际位置与预测位置之间的平均均方根误差。RTE较低，预测越准确

如今还面临哪些挑战？

泛化和 自学习



不同领域上进行测试，可能因为域之间的数据差异导致预测性能下降。可以考虑引入迁移学习，终身学习和对比学习。

效率和现 实世界部署



在现实生活中部署，需要考虑精度外，还需考虑系统储存，计算和能量的消耗

黑箱和 可解释性



深度学习模型通常被称为“黑箱”，因为其内部机制和决策过程不透明，用户难以理解模型是如何处理输入数据并生成输出的。可解释性是指能够理解和解释模型的决策过程。它旨在提供透明度，让用户能够知道模型是如何做出决策的，从而增强信任和接受度。

在未来研究中，需要揭示惯性定位神经模型背后的控制和物理模型，并确定哪些可以被学习。可以考虑引入贝叶斯深度学习为模型预测提供可解释性。

数据收集和 基准测试



数据质量很大程度影响深度学习模型，然而获得多样化数据可能既昂贵又耗时，并且获得准确地面真值标签具有挑战性。KITTI数据集通常被作为评估基于学习的VO标准。但仍缺乏通用基准。

如今还面临哪些挑战？

失效案例和物理约束



DNN模型不总是可靠的，偶尔会产生大的预测误差。因此要增强DNN预测鲁棒性。可以考虑对DNN模型施加物理约束或将深度学习与物理模型结合。

深度传感器融合



融合面临传感器数据格式多样化，时间同步，传感器校准复杂性等挑战，需要不断适应和定制以便能有更好的性能。

新深度学习方法



新的结构模型，如Transformer,扩散模型，生成模型以及新的学习方法可能有望增强惯性定位，此外，神经渲染，语音合成可能为开发惯性定位系统实现一定的贡献

鲁棒性和可靠性



实际应用中，处理不可预见的情况和确保可靠性相关挑战变得很关键。模型在面对极端条件可能遇到困难，未来需要多样化的训练数据，实施对抗性测试和新的学习模型，可以提高系统的整体可靠性，此外，连续监测，自适应算法和严格的认证标准也在提高可信度方面发挥重要作用。

谢谢你的观看